



SAPIENZA
UNIVERSITÀ DI ROMA

Approcci di Machine Learning per predire risposte ai farmaci nelle cellule tumorali

Facoltà di Scienze Matematiche, Fisiche e Naturali
Laurea Magistrale in Scienze Matematiche per l'Intelligenza Artificiale

Francesco Caperna

Matricola 2052076

Relatrice

Prof.^{ssa} Livia Perfetto

Anno Accademico 2024/2025

Ringraziamenti

Desidero innanzitutto menzionare le persone che mi hanno aiutato nell'elaborazione di questo lavoro.

Ringrazio la Professoressa Livia Perfetto per l'idea e per la guida fornita nella realizzazione di questo elaborato e per avermi introdotto e accolto nel Suo laboratorio, dove ho avuto la fortuna di conoscere persone splendide.

Ringrazio la Dottoressa Veronica Venafra per il prezioso aiuto nella realizzazione della tesi ed, in particolare, per il contributo essenziale nell'elaborazione dell'idea e nell'utilizzo di SignalingProfiler.

Ringrazio la Dottoressa Eleonora Meo per il fondamentale contributo nel preprocessing e nella pulizia dei dati trascrittomici.

Ringrazio, infine, tutto il laboratorio per essermi stato sempre di supporto in questi mesi.

Sommario

Questa tesi si propone come strumento per affrontare il problema cruciale delle cure specializzate a pazienti con diagnosi di tumore.

In particolare, sono stati realizzati dei modelli di Machine Learning e Deep Learning sulle cellule in vitro, derivate dai pazienti, per predire la sensibilità e l'IC₅₀ sui farmaci attraverso l'utilizzo dei fattori di trascrizione, i cui valori sono stati generati dall'espressione genica delle linee cellulari attraverso l'algoritmo SignalingProfiler⁽¹⁾. In particolare, è stato sviluppato un selezionatore dei farmaci utilizzando le migliori performance riscontrate sul test di validazione. In seguito, sono stati selezionati e studiati i 30 farmaci più performanti che hanno confermato ottimi risultati anche nel test set (Figure 2.5, 2.8 e 2.9), soprattutto considerando la complessità del segnale biologico e la scarsa disponibilità di dati, dimostrata in articoli simili nella letteratura scientifica. Successivamente, il modello relativo al farmaco *Trametinib* è stato anche trasferito e applicato al profilo genomico di 15 pazienti, dimostrando buona capacità di generalizzazione.

Infine, per interpretare ognuno dei 30 modelli, sono stati individuati i biomarcatori che incidono maggiormente nella risposta al farmaco, sia nelle linee cellulari che per i pazienti, attraverso le rappresentazioni SHAP⁽²⁾, le quali hanno dimostrato ottima coerenza biologica con articoli presenti in letteratura e dalla cui analisi potrebbero essere individuate anche nuove correlazioni biologiche tra fattori di trascrizione e la sensibilità ai farmaci.

Indice

Ringraziamenti	i
1 Introduzione	1
1.1 Come valutare la risposta ai farmaci	1
1.2 Database	2
1.2.1 Cancer Cell Line Encyclopedia (CCLE)	2
1.2.2 Genomics of Drug Sensitivity in Cancer (GDSC)	3
1.3 Geni e fattori di trascrizione	4
1.4 SignalingProfiler	5
1.5 Obiettivo della tesi e confronto con studi precedenti	5
1.5.1 A Performance evaluation of Drug Response prediction models for individual drugs ⁽³⁾	6
1.5.2 Scopo della tesi	8
2 Cellule in Vitro	9
2.1 Preprocessing Dataset	9
2.1.1 Trascrittomica	9
2.1.2 Drug Screening	10
2.1.3 Integrazione dei due dataset e divisione per allenamento dei modelli	11
2.1.4 Oversampling	11
2.2 Drug Selector	12
2.3 Modelli e Risultati	13
2.3.1 Modello Baseline	13
2.3.2 Impostazione e Iperparametri in comune dei modelli	14
2.3.3 Sensibilità	15
2.3.4 IC ₅₀ e Sensibilità	19
2.4 Interpretabilità dei modelli	23
3 Pazienti	28
3.0.1 Fedratinib	28
4 Discussione	31
4.0.1 Discussione	31
4.0.2 Metodi	31
Bibliografia	34

Capitolo 1

Introduzione

Il cancro è una delle principali cause di morte ed è caratterizzato da una grande eterogeneità biologica, sia tra i pazienti che tra i tumori⁽⁴⁾. Il tumore insorge quando un nucleo di cellule accumula un numero di mutazioni tali da indurre una crescita incontrollata del tessuto, chiamata massa tumorale. Per questo motivo è di fondamentale importanza trovare delle cure personalizzate in grado di bloccare la crescita ed indurre la morte di queste cellule, rispondendo alle esigenze di ciascun individuo.

Gli studi preclinici sono condotti prima che un farmaco o un trattamento venga testato sugli umani. Questi studi vengono effettuati utilizzando modelli in vitro, generalmente linee cellulari immortalizzate derivate dai tumori dei pazienti. Le linee cellulari permettono di riprodurre su scala di laboratorio la biologia del tumore e sono ampiamente utilizzate in tali studi. Inoltre, queste permettono di valutare l'efficacia e la tossicità di un farmaco prima di passare alla fase di sperimentazione clinica, che è di difficile praticabilità sia per ragioni etiche e normative che a causa degli elevati costi⁽⁵⁾. Tuttavia, è importante sottolineare che le linee cellulari rappresentano pur sempre dei modelli ed in quanto tali non riflettono con precisione ciò che accade nella realtà poiché qui intervengono numerose altre variabili tra cui l'interazione delle cellule tumorali con i tessuti adiacenti. Un'altra importante caratteristica delle linee cellulari è che queste sono state ampiamente caratterizzate sotto diversi aspetti, nel corso delle ultime decadi, pertanto se ne conosce approfonditamente il profilo molecolare.

1.1 Come valutare la risposta ai farmaci

In fase preclinica un farmaco viene testato in tossicità ed efficacia su modelli in vitro, attraverso la misura dell' IC_{50} .

L' IC_{50} (Inhibitory Concentration 50) è definita come la concentrazione di un farmaco necessaria per inibire un processo biologico del 50%. In particolare, nel contesto tumorale, l' IC_{50} è la concentrazione di un farmaco necessaria per indurre l'apoptosi, ovvero la morte cellulare, nel 50% delle linee cellulari di una popolazione in coltura dopo un tempo specificato di trattamento⁽⁶⁾

Derivato l' IC_{50} dagli esperimenti in laboratorio, è possibile successivamente ricavare la sensibilità di un farmaco a una linea cellulare definendo una soglia critica sotto la quale la cellula è definita sensibile.

1.2 Database

Le realizzazioni di dataset come Cancer Cell Line Encyclopedia (CCLE)⁽⁷⁾ e Genomics of Drug Sensitivity in Cancer (GDSC)⁽⁸⁾ sono essenziali nello studio del cancro in quanto raccolgono i dati delle cellule in vitro.

Nei prossimi due paragrafi introdurrò questi due database.

1.2.1 Cancer Cell Line Encyclopedia (CCLE)




Figura 1.1 Modificato da⁽⁸⁾ **a.** Descrizione della distribuzione dei tumori per linea cellulare. **b.** Matrice di correlazione del numero di copie cromosomiche tra linee cellulari e tumori primari. **c.** Matrice di correlazione dell'espressione genica tra linee cellulari e tumori primari. **d.** Matrice di correlazione del profilo mutazionale tra linee cellulari e tumori.

Il *Cancer Cell Line Encyclopedia* (CCLE) è un'iniziativa frutto della collaborazione di *Broad Institute*, *Dana-Farber Cancer Institute*, *Harvard Medical School* e *Novartis* pubblicata nel 2012 con l'obiettivo di raccogliere linee cellulari il più possibile rappresentative dei tumori umani, caratterizzandole con il loro profilo genomico.

Il dataset originale raccoglieva l'espressione genomica di 947 linee cellulari tumorali coltivate in laboratorio appartenenti a 36 tipi di tumore diversi [1.1.a] insieme ai profili di 24 farmaci anti-cancro ottenuti su un sottoinsieme di 479 linee cellulari.

In particolare, questi campioni sono caratterizzati dai seguenti profili genomici:

- **Espressione genica (mRNA)**
- **Numero di copie cromosomiche**
- **Profilo mutazionale**

Inoltre, per il sottoinsieme di 479 linee cellulari associate ai profili farmacologici, sono stati raccolti anche i dati relativi alle loro risposte come *EC₅₀*, *IC₅₀*, *Amax* e *Activity Area (AA)*.

Infine, confrontando i profili genomici delle linee cellulari con i tumori umani primari resi disponibili grazie a diversi database (Tumorscape14, expO, MILE e COSMIC) si sono osservate le seguenti correlazioni:

- **Espressione genica (mRNA):** coefficiente di correlazione mediana di 0.77 con un range tra 0.52 e 0.94. [1.1.b]

- **Numero di copie cromosomiche (copy number):** coefficiente di correlazione mediana di 0.60 con un range tra 0.29 e 0.77. [1.1.c]
- **Profilo mutazionale:** coefficiente di correlazione mediana di 0.71 con un range tra -0.06 e 0.97. [1.1.d]

Queste forti correlazioni hanno confermato come queste linee cellulari riflettano i profili genomici dei pazienti.

1.2.2 Genomics of Drug Sensitivity in Cancer (GDSC)

Il *Genomics of Drug Sensitivity in Cancer* (GDSC) è un'iniziativa frutto della collaborazione di *Wellcome Trust Sanger Institute* e *Wellcome Trust Sanger Institute* pubblicata nel 2016. Anche in questo caso, lo scopo era di collezionare linee cellulari il più possibile rappresentative dei tumori umani. A differenza del CCLE nel quale si prediligeva la caratterizzazione genica, il focus principale di questo database è identificare le relazioni tra alterazioni molecolari nei tumori e la risposta farmacologica nelle linee cellulari tumorali.

In questo dataset si identificano 29 tessuti mappati in 1.001 linee cellulari associate a 265 farmaci anti-cancro.

In particolare, le linee cellulari sono caratterizzate da:

- WES
- Numero di copie cromosomiche
- Espressione genica
- Metilazione DNA




Figura 1.2 Modificato da⁽⁷⁾ Pipeline GDSC

Nella figura 1.2 viene presentata la pipeline della costruzione del dataset GDSC. Qui viene raffigurato come gli autori abbiano inizialmente mappato le alterazioni molecolari osservate nei tumori dei pazienti nelle 1001 linee cellulari tumorali. Successivamente, hanno osservato l'IC₅₀ e quindi la sensibilità del farmaco, per poi ipotizzare la risposta reale dei tumori ai farmaci analizzati.




Figura 1.3 Modificato da ⁽⁷⁾. (a) Distribuzione coefficiente di correlazione di Pearson per IC₅₀ di ogni droga solo sulle linee cellulari pancreatiche. (b) Risposta al farmaco di Trametinib solo sulle linee cellulari pancreatiche.

Inoltre, sono state compiute delle analisi per verificare la corrispondenza tra i tumori dei pazienti e le linee cellulari osservando buone correlazioni. Infine, gli autori, con l'obiettivo di spiegare il dataset, hanno sia cercato di individuare dei biomarcatori rilevanti nella risposta al farmaco che dei metodi predittivi, computazionali e di machine learning (ElasticNet), per predire rispettivamente la sensibilità e l'IC₅₀ delle linee cellulari. Nella figura 1.3 vengono rappresentati due modelli predittivi, solo sulle linee cellulari pancreatiche, che hanno prodotto i seguenti risultati:

- Nella figura 1.3.a è rappresentata la distribuzione del coefficiente di correlazione di Pearson sull' IC₅₀ utilizzando il modello di ML ElasticNet. Si osserva dunque che l'espressione genica è il miglior strumento predittivo per l'IC₅₀ (quindi anche per la sensibilità) e che il *Trametinib* rappresenti il farmaco con i migliori risultati.
- Nella figura 1.3.b, gli autori propongono metodi predittivi computazionali che, applicati al farmaco Trametinib, raggiungono una *precision* di 0.63 e un *recall* di 0.41, con un *F1-score* massimo pari a 0.4977.

1.3 Geni e fattori di trascrizione

In questo paragrafo verrà spiegata la differenza tra geni e fattori di trascrizione in quanto essenziale per comprendere ciò che verrà trattato nella tesi.

Un **gene** è una sequenza di DNA situata in una posizione specifica (locus) su un cromosoma, che contiene l'informazione necessaria per produrre, durante il processo di trascrizione, un trascritto di RNA che può avere un ruolo funzionale, o che può portare alla sintesi di una proteina, nella traduzione.

La struttura semplificata del gene è la seguente:

- **Sequenze regolatorie:** regioni del DNA che controllano l'espressione del gene, regolando l'efficienza della trascrizione. In queste sequenze si legano i *fattori di trascrizione* e altri elementi regolatori (come coattivatori o corepressori), che modulano l'inizio e l'efficienza della trascrizione. Possono trovarsi in prossimità del gene (come i promotori) oppure a distanza (come enhancer e silencer).
- **Esoni:** contengono le sequenze codificanti del gene.
- **Introni:** Contengono le sequenze non codificanti del gene.
- **Terminazione:** porzione del gene che segnala alla RNA polimerasi il punto in cui concludere la trascrizione.

Un **fattore di trascrizione** è una proteina regolatrice che si lega a delle sequenze specifiche del DNA come promotori, enhancer o silencer per attivare o reprimere la trascrizione di un *gene*. Queste molecole regolatorie si possono legare a diversi geni e per questo motivo sono in numero decisamente più ridotto rispetto a quest'ultimi.

1.4 SignalingProfiler

SignalingProfiler⁽¹⁾ è uno strumento computazionale in grado di utilizzare dati multi-omici (trascrittomica, proteomica e fosfoproteomica) e reti prior-knowledge per derivare reti di segnalazione e stimare le attività di diverse categorie di molecole regolatorie tra cui i fattori di trascrizione, le fosfatasi e altre proteine di segnalazione.




Figura 1.4 Modificato da⁽¹⁾. Transcription Factor Enrichment Analysis (TFEA)

In particolare, SignalingProfiler integra metodi di inferenza dell'attività proteica, come l'algoritmo *Viper*. In questo paragrafo approfondirò l'inferenza dei fattori di trascrizione (TFEA) in quanto è quella che è stata utilizzata nel preprocessing dei dati.

L'algoritmo *Viper*, utilizzato nella *TFEA*, analizza il comportamento dei *regoloni*, ovvero l'insieme dei geni noti per essere attivati o repressi da uno specifico fattore di trascrizione. Attraverso il confronto della loro espressione genica, questo approccio computazionale assegna un punteggio, detto *activity score*, rappresentativo dell'attività funzionale di questi regolatori trascrizionali.

La figura 1.4 illustra in maniera esemplificativa questo processo. Osserviamo quindi come al fattore di trascrizione TF siano collegati 4 geni, poichè la maggior parte dei geni attivati da TF sono spenti (azzurri), il TF viene stimato essere inattivo. Dall'insieme dell'attività (sovraespressione o sottoespressione) di questi target si inferisce, infine, l'*activity score*.

1.5 Obiettivo della tesi e confronto con studi precedenti

L'obiettivo di questa tesi è quello di utilizzare le cellule in vitro per realizzare dei modelli in grado di predire l'IC₅₀ e la sensibilità rispetto a un farmaco dai quali dedurre successivamente la risposta dei pazienti.




Figura 1.5 Pipeline Tesi

Per realizzare ciò, come illustrato nella figura 1.5, ho realizzato N modelli di Machine Learning e Deep Learning corrispondenti ai rispettivi farmaci in grado di predire l'IC₅₀ e la sensibilità dall'attività dei *fattori di trascrizione* inferiti dall'*espressione genica* delle cellule in vitro. Come mostrato nella figura 1.3, infatti, l'espressione genica rappresenta il miglior strumento predittivo tra quelli proposti.

1.5.1 A Performance evaluation of Drug Response prediction models for individual drugs⁽³⁾

Il problema presentato sopra è stato affrontato anche in studi precedenti, tra cui l'articolo⁽³⁾, il quale si pone come obiettivo quello di predire l'IC₅₀ dal dataset *CCLE* [1.2.1]. Gli autori hanno costruito 24 modelli corrispondenti ai 24 farmaci del dataset per predire su ciascuno di essi l'IC₅₀.




Figura 1.6 Modificato da⁽³⁾. **a.** Risultati utilizzando l'espressione genica **b.** Risultati utilizzando la mutazione genica

In particolare, per ognuno dei farmaci, il dataset conteneva 504 linee cellulari e da ciascun modello sono stati ottenuti i seguenti risultati [1.6] :

- I modelli di DL (Deep Learning) hanno ottenuto come R^2 valori nel range tra -7.405 e 0.331 e come $RMSE$ valori nel range tra 0.284 e 3.563
- I modelli di ML (Machine Learning) hanno ottenuto come R^2 valori nel range tra -8.113 e 0.470 e come $RMSE$ valori nel range tra 0.274 e 2.697

Come possiamo notare, alcuni farmaci hanno R^2 negativo e quindi rappresentano una predizione peggiore di quella casuale. Per ovviare a questo problema, gli autori hanno selezionato il farmaco che in tutti i modelli garantiva il miglior risultato, ovvero il *Panobinostat*.




Figura 1.7 Modificato da⁽³⁾. **a.** Applicazione del modello Ridge per il Panobinostat alle linee cellulari di GC (CCLE e GDSC) e ai dataset di pazienti (GSE118916 e TCGA). Risultati per **b** CCLE GC, **c** GDSC GC, **d** GSE118916 e **e** TCGA GC. Explainability per **f** CCLE GC, **g** GDSC GC, **h** GSE118916 e **i** TCGA GC

Il miglior modello per questo farmaco, ottenuto utilizzando la Ridge Regression, è stato testato sul sottoinsieme di cellule in vitro relativi solo al cancro gastrico (GC), tessuto colpito dal farmaco in questione, ottenendo un R^2 di 0.980 nel dataset CCLE [1.7.b](18 cellule) e 0.520 nel dataset GDSC [1.7.c] (24 cellule). Ciò dimostra che, nonostante l' R^2 su tutte le cellule sia 0.47, questo ovviamente aumenta se nel test si misurano solo il sottoinsieme di cellule relative al tessuto colpito dal farmaco.

Inoltre, a causa dell'assenza dei dati relativi alle risposte sui pazienti, non si sono potute fare delle analisi tra le risposte farmacologiche predette e osservate nei dataset di GSE118916 [1.7.d]

e di TCGA GC [1.7.e], che contenevano solo l'espressione genica dei pazienti. Nonostante questo, è importante sottolineare che i dati relativi ai pazienti mostravano una risposta eterogenea al *Panobinostat* sulle cellule gastriche (TCGA GC) [1.7.e].

Nella conclusione dell'articolo, gli autori hanno cercato di identificare i biomarcatori più rilevanti nella predizione attraverso l'*explainability* dei modelli [1.7]. Come si può osservare, la scala dei valori che contribuisce alla predizione è estremamente ridotta e questo sembra incidere negativamente sulla capacità predittiva. Infatti, al diminuire della grandezza della scala, si osserva una diminuzione delle performance del modello. In particolare, tali dimensioni microscopiche sono dovute al fatto che i geni in una cellula sono nell'ordine delle decine di migliaia, come vedremo dopo, e ciò rappresenta un ostacolo sia per la predizione che per l'interpretabilità del modello stesso.

1.5.2 Scopo della tesi

Nei modelli predittivi sviluppati in studi simili, tra cui quelli nell'articolo⁽³⁾ analizzato, si focalizza l'attenzione prevalentemente sull'IC₅₀. Lo scopo della mia tesi è quello di dare particolare rilievo nel predire la sensibilità delle linee cellulari ai farmaci in quanto, come visto nell'introduzione, da questa informazione si ipotizza la potenziale risposta di un paziente al trattamento.

Per realizzare quanto detto, mi ripropongo di sviluppare due modelli distinti che seguono diverse pipeline al fine di confrontarli. Nel primo modello, intendo affrontare il problema come una classificazione, stimando direttamente la probabilità che una linea cellulare risulti sensibile al farmaco. Nel secondo modello, invece, miro a predire l'IC₅₀ tramite regressione e successivamente, ad inferire la sensibilità, applicando una soglia definita.

Come evidenziato nella letteratura scientifica, i risultati ottenuti in studi simili non sono ottimali a causa della limitazione dei dati (solo 504 cellule per ogni modello) e della complessità biologica del segnale. Per questo motivo, è di fondamentale importanza l'interpretabilità dei modelli sia per essere più consapevoli delle ragioni biologiche che determinano la risposta di un farmaco che per identificare nuovi biomarcatori. In quest'ottica, a differenza dell'articolo descritto prima, mi ripropongo di utilizzare, come features dei modelli, i fattori di trascrizione ed i relativi punteggi di attività, derivati dall'espressione genica. Questo impatterà notevolmente sull'interpretabilità perché diminuirà drasticamente il numero delle features.

Come visto nell'articolo⁽³⁾, inoltre, alcuni modelli performano peggio rispetto ad un modello baseline casuale. Per questo motivo, intendo implementare un selezionatore di farmaci in grado di fare un ranking dei migliori modelli sulla base delle performance sul validation set.

Inoltre, alla luce dello scopo finale di attuare questi modelli sui pazienti, miro a privilegiare la robustezza dei modelli sia nella selezione delle features, come visto prima, che nella progettazione dell'architettura dei modelli. A tale scopo, a differenza dell'articolo⁽³⁾, implementerò modelli ensemble generalmente considerati più stabili.

Infine, a differenza dell'articolo⁽³⁾, pianifico di analizzare i farmaci dal dataset GDSC, in quanto più numerosi, poi associati alle linee cellulari del dataset CCLE poiché offrono una descrizione più accurata del profilo genomico delle cellule.

Capitolo 2

Cellule in Vitro

2.1 Preprocessing Dataset

In questo capitolo andremo ad affrontare le sfide relative al preprocessing dei dataset per le cellule in vitro.

Come detto in precedenza, il dataset per il drug screening è quello presente nel GDSC mentre quello per l'espressione genica (trascrittomica) è quello del CCLE e lo scopo è quello di integrarli.

2.1.1 Trascrittomica

Il dataset trascrittomico per l'espressione genica è rappresentato da una matrice $X \in \mathbb{R}^{m \times n}$, dove $m = 196,520$ indica il numero totale di elementi trascrizionali (comprendenti combinazioni di geni e trascritti), e $n = 1,021$ rappresenta il numero di linee cellulari.

Per ridurre la dimensionalità e ottenere una rappresentazione a livello genico, è stata effettuata un'aggregazione per gene. In particolare, per ogni gene g_j , l'espressione aggregata $\bar{x}_{g_j}$ è stata calcolata come media delle espressioni dei trascritti associati:

$$\bar{x}_{g_j} = \frac{1}{T_j} \sum_{t=1}^{T_j} x_{t,j}$$

dove T_j è il numero di trascritti associati al gene g_j , e $x_{t,j}$ è il valore di espressione del trascritto t nella linea cellulare j .

Successivamente, i valori di espressione aggregata sono stati sottoposti a trasformazione logaritmica per attenuare l'effetto di valori estremi e rendere la distribuzione più simmetrica:

$$x'_{g_j} = \log(\bar{x}_{g_j} + 1)$$

Infine, per ciascuna linea cellulare j , i valori di espressione sono stati standardizzati tramite la normalizzazione z-score:

$$z_{g_j} = \frac{x'_{g_j} - \mu_j}{\sigma_j}$$

dove μ_j e σ_j rappresentano rispettivamente la media e la deviazione standard dei valori di espressione x'_{g_j} nella linea cellulare j .

Questa trasformazione serve per identificare i geni sovraespressi ($z > 0$) e sottoespressi ($z < 0$). Infine, sono stati rimossi tutti i geni che non codificavano le proteine perchè non sono direttamente coinvolti in processi rilevanti per la risposta farmacologica e per ridurre il numero delle features dei modelli.

Alla fine di questo preprocessing, la dimensione della trascrittomico era $18,832 \times 1,021$.

Dall'espressione genica ai fattori di trascrizione

Successivamente, grazie all'utilizzo del software SignalingProfiler, dai geni sono stati dedotti i fattori di trascrizione, portando il numero di features da 18.832 a 493. Questa enorme diminuzione dei dati è stata fondamentale per i seguenti motivi:

- **Efficienza:** La diminuzione delle features di circa 40 volte ha indubbiamente dei vantaggi dal punto di vista computazionale perchè rende più efficiente e veloce l'applicazione dei modelli.
- **Interpretabilità:** la diminuzione del numero di features rende il modello più interpretabile. Infatti, come visto nell'articolo⁽³⁾, le dimensioni della scala della contribuzione dei geni al risultato finale, erano microscopiche. Questo era dovuto al fatto che, essendo le features numerose, è molto probabile che esse siano correlate tra loro e questo rende l'interpretazione del modello meno precisa.
- **Diminuzione del rumore** I fattori di trascrizione riducono il rumore presente nei dati trascrittomici e questo li rende estremamente adatti allo scopo di rendere i modelli più robusti per applicarli ai pazienti.
- **Feature selection biologicamente guidata** In generale, la diminuzione delle features, mantenendo le stesse informazioni, rende i modelli più efficienti e più robusti soprattutto in quelli di DL. Infatti, a questo scopo molte volte si applicano delle tecniche per ridurre la dimensionalità come PCA. Il vantaggio di SignalingProfiler, invece, è quello che non si basa solo sulla correlazione ma anche sulla causalità grazie alle reti prior-knowledge
- **Prospettiva diversa** Infine, la trasformazione dei geni in fattori di trascrizione può essere molto utile nell'interpretabilità dei modelli in quanto può identificare biomarcatori diversi rispetto a quelli osservati nei geni.

2.1.2 Drug Screening

Il dataset del drug screening per l'espressione genica è rappresentato da una matrice $X \in \mathbb{R}^{a \times b}$, dove $a = 216$ indica il numero di farmaci, e $b = 990$ rappresenta il numero di linee cellulari.




Figura 2.1 (a) Distribuzione nel Drug Screening dell'IC₅₀. (b) Distribuzione nel Drug Screening della sensibilità.

Per ogni combinazione linea cellulare e farmaco sono stati misurati l' IC_{50} e la **sensibilità** ottenendo le distribuzioni nella figura 2.1. Come si può osservare, la distribuzione dell' IC_{50} segue approssimativamente una distribuzione normale mentre quella della sensibilità è notevolmente sbilanciata in favore di quella delle resistenti ai farmaci (R).

2.1.3 Integrazione dei due dataset e divisione per allenamento dei modelli

I due dataset sono stati uniti ottenendo per ogni farmaco una matrice $X \in \mathbb{R}^{b \times m}$, dove $0 < b \leq 624$ rappresenta il numero di linee cellulari uniche in comune tra i due dataset e $m = 493$ il numero di fattori di trascrizione. Il numero di linee cellulari in questo dataset varia per ciascun farmaco a causa della mancanza di disponibilità di tutte le risposte farmacologiche per ogni linea cellulare. Inoltre, le distribuzioni dell' IC_{50} e della *sensibilità* rimangono invariate rispetto al drug screening confermando il forte sbilanciamento osservato nella figura 2.1.

Infine, per ciascun dataset relativo ad ogni farmaco è stata effettuata la seguente divisione:

- **Training e Validation:** 80%
- **Test:** 20%

Questa suddivisione è stata fatta mantenendo la distribuzione del numero di linee cellulari sensibili nel training e nel validation set simile. Ciò è stato fatto a causa del numero limitato di cellule sensibili nel dataset, che poteva costituire un problema nell'analisi del test set.

2.1.4 Oversampling

Come detto nell'introduzione, lo scopo principale della tesi è quello di predire la sensibilità ma, come visto nella 2.1, il dataset è particolarmente sbilanciato in favore delle linee cellulari resistenti. Questo costituisce un problema nella predizione perchè il modello potrebbe imparare a predire solo la classe maggioritaria risultando inutile (f1-score = 0).

Per evitare tutto questo, soprattutto nel task della classificazione, è stato utilizzato SMOTE⁽⁹⁾, una tecnica di oversampling introdotta in questo paragrafo.

SMOTE

SMOTE (Synthetic Minority Over-sampling TEchnique) è una tecnica di oversampling utilizzata per affrontare il problema dei dataset sbilanciati. Questo algoritmo migliora le prestazioni dei classificatori creando nuovi esempi sintetici dalla classe minoritaria invece di duplicare quelli già esistenti.

Come descritto nello pseudocodice riportato di seguito estratto dall'articolo⁽⁹⁾, l'algoritmo funziona nel seguente modo:

1. **Selezione dei vicini:** per ogni esempio della classe minoritaria, vengono trovati i suoi k vicini più prossimi appartenenti alla stessa classe.
2. **Generazione di esempi sintetici:** si seleziona a caso uno dei k vicini. Si crea un nuovo punto sintetico lungo il segmento che collega il punto originale al vicino selezionato, scegliendo una posizione casuale tra i due:

$$\text{punto sintetico} = x_i + \text{rand}(0, 1) \cdot (x_{nn} - x_i)$$

dove x_i è un esempio della classe minoritaria, e x_{nn} uno dei suoi vicini.

3. **Ripetizione:** il processo viene ripetuto per ogni esempio della classe minoritaria fino a generare il numero desiderato di esempi sintetici.

Algoritmo 1 SMOTE(T, N, k)

Require: Number of minority class samples T , amount of SMOTE $N\%$, number of nearest neighbors k

Ensure: $(N/100) \times T$ synthetic minority class samples {If N is less than 100%, randomize the minority class samples as only a random percent of them will be SMOTEd.}

```

1: if  $N < 100$  then
2:   Randomize the  $T$  minority class samples
3:    $T \leftarrow (N/100) \times T$ 
4:    $N \leftarrow 100$ 
5: end if
6:  $N \leftarrow \text{int}(N/100)$  {The amount of SMOTE is assumed to be in integral multiples of 100.}
7:  $k \leftarrow$  Number of nearest neighbors
8:  $\text{numattrs} \leftarrow$  Number of attributes
9:  $\text{Sample}[][] \leftarrow$  array for original minority class samples
10:  $\text{newindex} \leftarrow 0$  {Keeps a count of number of synthetic samples generated}
11:  $\text{Synthetic}[][] \leftarrow$  array for synthetic samples
    {Compute  $k$  nearest neighbors for each minority class sample only}
12: for  $i \leftarrow 1$  to  $T$  do
13:   Compute  $k$  nearest neighbors for  $i$ , and save the indices in the  $\text{nnarray}$ 
14:    $\text{Populate}(N, i, \text{nnarray})$ 
15: end for
     $\text{Populate}(N, i, \text{nnarray})$  {Function to generate the synthetic samples}
16: while  $N \neq 0$  do
17:   Choose a random number between 1 and  $k$ , call it  $nn$  {This step chooses one of the  $k$  nearest neighbors of  $i$ }
18:   for  $\text{attr} \leftarrow 1$  to  $\text{numattrs}$  do
19:      $\text{dif} \leftarrow \text{Sample}[\text{nnarray}[nn]][\text{attr}] - \text{Sample}[i][\text{attr}]$ 
20:      $\text{gap} \leftarrow$  random number between 0 and 1
21:      $\text{Synthetic}[\text{newindex}][\text{attr}] \leftarrow \text{Sample}[i][\text{attr}] + \text{gap} \times \text{dif}$ 
22:   end for
23:    $\text{newindex} \leftarrow \text{newindex} + 1$ 
24:    $N \leftarrow N - 1$ 
25: end while
26: return End of Procedure =0

```

Inoltre, l'algoritmo ha i seguenti vantaggi:

- **Evita l'overfitting:** a differenza del semplice duplicamento, SMOTE crea nuovi punti che *espandono* la regione decisionale della classe minoritaria.
- **Migliore generalizzazione:** consente ai classificatori di apprendere confini decisionali più ampi e rappresentativi per la classe minoritaria.

2.2 Drug Selector

Come riportato in precedenza, Park e collaboratori hanno generato modelli predittivi farmacologici specifici in una gamma di linee cellulari, predicendo per ciascuno l'IC₅₀⁽³⁾. Tuttavia, si osserva che in molti modelli l' R^2 era negativo. Per ovviare a questo problema, ho ideato un modello che selezionasse i migliori farmaci sulla base dei risultati sulla cross-validation.

In particolare, come si può osservare nella figura 2.2, il dataset di training è stato diviso in 5 sottoinsiemi ed è stata effettuata una 5-fold cross validation. Per ogni split sono stati implementati due modelli Random Forest per predire separatamente sia l' IC_{50} che la *sensibilità*. Per valutare i risultati sono stati presi in considerazione l' R^2 per la regressione (IC_{50}) e l' AUC_{PR} per la classificazione (*sensibilità*) sul sottoinsieme della validation (blu in figura).




Figura 2.2 Drug selector

A questo scopo è stato introdotto uno score che potesse tenere in considerazione entrambe le metriche per ogni split di validazione:

$$\text{score}_i = R^2 \cdot (\text{AUC}_{PR})^2 \quad \text{con } i \in \{1, \dots, 5\}$$

Infine, lo score complessivo di ciascun farmaco è dato dalla media degli score per ogni split:

$$\text{score}_{\text{farmaco}} = \frac{1}{5} \sum_{i=1}^5 \text{score}_i$$

Dallo score del farmaco è stato stilato un ranking che classificava i modelli. Nei modelli sviluppati in questa tesi sono stati tenuti in considerazione solo i top 30 farmaci con punteggio positivo.

A differenza dell'articolo, dove veniva selezionato il *Trametinib* poiché in tutti i modelli raggiungeva le migliori performance sul test set, qui è stato implementato questo sistema appena spiegato per evitare che questi risultati potessero dipendere anche dal sottoinsieme di linee cellulari nel test set.

2.3 Modelli e Risultati

2.3.1 Modello Baseline

Poiché il nostro dataset mostra una distribuzione sbilanciata delle classi (90% **R** (resistenza) e 10% **S** (sensibilità)), come analisi preliminare, andremo ad esaminare l' **F1-score** in diversi scenari, sia casuali che deterministici, in modo tale da ottenere dei modelli base di riferimento.

In particolare, consideriamo due casistiche:

- **Classificatore casuale uniforme (50%-50%)**: il modello assegna le due classi con probabilità uguale, indipendentemente dalla distribuzione reale. In questo caso, la

precision e il *recall* per **S** saranno rispettivamente 0.1 e 0.5, quindi:

$$\text{F1-score} = \frac{2 \cdot 0.1 \cdot 0.5}{0.1 + 0.5} \approx 0.167$$

- **Classificatore casuale proporzionale alla distribuzione (90%-10%)**: il modello assegna casualmente etichette rispettando la distribuzione reale. In questo caso, la *precision* e il *recall* per **S** saranno entrambe 0.1, quindi:

$$\text{F1-score} = \frac{2 \cdot 0.1 \cdot 0.1}{0.1 + 0.1} = 0.1$$

Infine, un classificatore che predice sempre una classe avrà i seguenti **F1-score**:

- **Classe maggioritaria (R)**: In questo caso, la *precision* e il *recall* per **S** saranno entrambi 0, quindi anche l'**F1-score** sarà 0.
- **Classe minoritaria (S)**: In questo caso, la *precision* e il *recall* per **S** saranno rispettivamente 0.1 e 1, quindi:

$$\text{F1-score} = \frac{2 \cdot 0.1 \cdot 1}{0.1 + 1} \approx 0.182$$

Questi valori rappresentano dei baseline di riferimento per i risultati successivi. Quindi, ogni modello che non supera almeno la soglia di 0.182 come F1-score, non mostra alcuna capacità predittiva utile.

2.3.2 Impostazione e Iperparametri in comune dei modelli

Modelli DL

Per ognuno dei modelli DL, la cui architettura è descritta nell'immagine 2.3, è stato applicato Early Stopping per prevenire l'overfitting e sono stati utilizzati i seguenti iperparametri sui quali è stato effettuato l'Hyperparameter Tuning:

- **Dimensione dei layer**: il numero di neuroni (dim).
- **Dropout** (solo per le MLP): tecnica di regolarizzazione che esclude in maniera casuale una parte dei neuroni durante l'addestramento per ridurre overfitting.
- **Learning rate**: controlla l'ampiezza dei passi compiuti durante l'aggiornamento dei pesi, influenzando la velocità e la stabilità della convergenza.

Per le CNN sono stati ottimizzati la dimensione dei layer e il learning rate, mentre per le MLP anche il valore del dropout.

Modelli ML

Per ognuno dei modelli ML sono stati utilizzati numerosi iperparametri sui quali è stato applicato l'Hyperparameter Tuning. Per questione di spazio, qui presentiamo solo quelli comuni a tutti i modelli:

- **n_estimators**: numero di alberi.
- **max_depth**: profondità massima degli alberi.




Figura 2.3 A sinistra si può osservare l'architettura CNN composta da tre strati convoluzionali 1D ciascuno con dimensione del kernel 3, funzione di attivazione ReLU e MaxPooling. Dopo l'operazione di flatten, i dati passano per uno strato denso (fully connected) con funzione di attivazione ReLU generando come output finale un singolo neurone con funzione di attivazione lineare (regressione) o sigmoidale (classificazione). A destra, invece, è rappresentata l'architettura MLP costituita da tre strati densi con funzione di attivazione ReLU e Dropout, che produce anch'essa come output finale un singolo neurone con funzione di attivazione lineare o sigmoidale a seconda del task.

2.3.3 Sensibilità

Modello

Il modello per predire la sensibilità sviluppato per ogni farmaco è un classificatore basato su un approccio ensemble che suddivide il training set in 5 fold come mostrato nella figura 2.2 e per ciascuno viene allenato un modello di ML o DL applicando l'oversampling *SMOTE* sulla parte di training come descritto nel paragrafo 2.1.4 allo scopo di produrre dati sintetici relativi alla classe dei sensibili. Il modello viene poi testato sul validation set dal quale viene calcolato

l' *AUC-PR* (Area Under Curve Precision-Recall). Alla fine del processo, la probabilità finale $\hat{p}$ di essere positivo viene stimata come media pesata delle probabilità restituite dai singoli modelli, utilizzando come peso l'*AUC-PR* ottenuto da ciascuno di essi sul rispettivo fold di validation.

$$\hat{p} = \frac{\sum_{i=1}^5 \text{AUC-PR}_i \cdot p_i}{\sum_{i=1}^5 \text{AUC-PR}_i}$$




Figura 2.4 Grafici realizzati per il farmaco *Trametinib* (a) Curve AUC ROC, AUC PR per Trametinib per il validation (blu) e il test set (arancione) con la migliore soglia calcolata sul validation set per *f1-score* (linea tratteggiata in rosso) (b) Precision-recall rispetto al cutoff (soglia probabilità) (c) Matrice di confusione del modello predittivo per Trametinib con *precision* di ≈ 0.63 , *recall* di ≈ 0.69 e *f1-score* di ≈ 0.66

In seguito, per calcolare l'appartenenza ad una specifica classe, viene individuata una soglia di probabilità al di sopra della quale la cellula è definita sensibile (**S**). In questo caso, come illustrato nella figura 2.4.a, la miglior soglia è calcolata individuando quella che massimizza l'*F1-score* nel validation set.

Inoltre, per ottimizzare i risultati, è stato effettuato un hyperparameter tuning, attraverso l'utilizzo della libreria *optuna*⁽¹⁰⁾ massimizzando l'*f1-score*, per ogni modello appartenente ad

ogni fold allo scopo di trovarne i migliori iperparametri. Questo è stato possibile perchè, a differenza dell'articolo⁽³⁾, le features (fattori di trascrizione) sono in numero molto inferiore.

Come descritto prima, la soglia di appartenenza alla classe positiva è stata determinata in modo tale da raggiungere l'f1-score migliore nel validation set. Tuttavia, è importante sottolineare che, a seconda del contesto, si possono utilizzare altri parametri nella scelta di tale soglia, come privilegiare le linee cellulari che sicuramente sono sensibili (precision) tralasciando quelle di cui si è meno sicuri o, al contrario, preferire prendere il maggior numero di linee cellulari sensibili (recall). A tale scopo, sono stati realizzati, per ogni farmaco, i grafici illustrati nella figura 2.4. In particolare, la figura 2.4.b può essere particolarmente utile nella scelta di tale soglia perchè, ad esempio, possiamo osservare che al di sopra del cut-off (probabilità) 0.85, nel farmaco *Trametinib* le linee cellulari osservate nel test set sono tutte sensibili.

Risultati

Nella tabella 2.5 vengono mostrati i risultati per ciascun farmaco su 6 tipi diversi di ensemble models:

- **RF**: La colonna RF si riferisce al modello che applica per ogni fold la Random Forest ottenendo una media su tutti i farmaci di f1-score di 0.6.
- **XGB**: La colonna XGB si riferisce al modello che applica per ogni fold XGBoosting ottenendo una media su tutti i farmaci di f1-score di 0.58.
- **Gradient Boosting**: La colonna Gradient Boosting si riferisce al modello che applica per ogni fold Gradient Boosting ottenendo una media su tutti i farmaci di f1-score di 0.57.
- **XGB RF GB**: La colonna XGB RF GB si riferisce al modello che applica su due fold XGBoosting, su altri due Random Forest e sull'ultimo Gradient Boosting ottenendo una media su tutti i farmaci di f1-score di 0.59.
- **mlp Sensitivity**: La colonna mlp Sensitivity si riferisce al modello che applica per ogni fold la MLP descritta nella figura 2.3 sulle migliori 20 features (fattori di trascrizione), ricavate dal modello Random Forest per ogni farmaco ,ottenendo una media su tutti i farmaci di f1-score di 0.57.
- **cnn Sensitivity**: La colonna CNN Sensitivity si riferisce al modello che applica per ogni fold la CNN descritta nella figura 2.3 sulle migliori 20 features (fattori di trascrizione), ricavate dal modello Random Forest per ciascun farmaco, ottenendo una media su tutti i farmaci di f1-score di 0.56.

Come si può osservare nella tabella 2.5, i risultati ottenuti sono simili. Nonostante ciò, è importante sottolineare che per ogni farmaco i modelli migliori possano differire.

Trametinib

Si ricorda che i risultati ottenuti sul *Trametinib* (vedi 1.2.2) sulle linee cellulari pancreatiche utilizzando metodi computazionali nel dataset della CCLE mostravano un f1-score di 0.4977. Si osserva, invece, come i modelli sviluppati sullo stesso farmaco [2.5] qui raggiungano un f1-score decisamente superiore (f1-score da 0.6 fino a 0.66 nei vari modelli) pur essendo testati su tutte le linee cellulari e non su un singolo tessuto specifico.

In particolare, la CNN sembra essere il modello che funziona meglio nella predizione, raggiungendo una precision di ≈ 0.63 e un recall di ≈ 0.69 con un F1-score di ≈ 0.66 , come illustrato nella figura 2.4.c.

	RF	XGB	Gradient_Boosting	XGB_RF_GB	mlp_Sensitivity	cnn_Sensitivity	Media farmaco
KIN001-260	0.75 0.60 0.51	0.73 0.60 0.49	0.72 0.55 0.51	0.75 0.60 0.57	0.70 0.53 0.41	0.75 0.57 0.47	0.73 0.57 0.49
TG101348	0.89 0.65 0.67	0.95 0.55 0.71	0.90 0.75 0.69	0.90 0.62 0.64	0.88 0.50 0.61	0.89 0.55 0.69	0.9 0.6 0.67
BX-912	0.95 0.75 0.67	0.92 0.68 0.65	0.94 0.77 0.69	0.95 0.76 0.58	0.88 0.69 0.71	0.89 0.70 0.69	0.92 0.72 0.66
QL-XI-92	0.76 0.63 0.57	0.72 0.58 0.56	0.76 0.64 0.56	0.75 0.65 0.54	0.76 0.57 0.56	0.75 0.58 0.59	0.75 0.61 0.56
Tubastatin A	0.76 0.65 0.51	0.74 0.63 0.48	0.78 0.67 0.56	0.78 0.66 0.49	0.70 0.60 0.50	0.67 0.54 0.43	0.74 0.63 0.5
GSK690693	0.71 0.69 0.59	0.70 0.63 0.52	0.71 0.68 0.56	0.70 0.64 0.55	0.70 0.60 0.56	0.67 0.56 0.54	0.7 0.63 0.55
XMD14-99	0.87 0.48 0.48	0.87 0.44 0.44	0.86 0.46 0.48	0.88 0.47 0.50	0.85 0.43 0.40	0.85 0.38 0.44	0.86 0.44 0.46
NPK76-II-72-1	0.96 0.74 0.55	0.96 0.75 0.67	0.96 0.73 0.56	0.96 0.73 0.70	0.94 0.50 0.50	0.93 0.38 0.49	0.95 0.64 0.58
Y-39983	0.82 0.77 0.65	0.73 0.72 0.63	0.78 0.76 0.61	0.77 0.74 0.62	0.76 0.72 0.61	0.74 0.71 0.59	0.77 0.74 0.62
AT-7519	0.96 0.37 0.55	0.97 0.58 0.33	0.97 0.59 0.40	0.98 0.50 0.50	0.95 0.34 0.40	0.97 0.46 0.46	0.97 0.47 0.44
KIN001-236	0.84 0.62 0.57	0.82 0.62 0.62	0.83 0.65 0.67	0.83 0.62 0.59	0.78 0.58 0.61	0.80 0.57 0.57	0.82 0.61 0.6
TL-2-105	0.89 0.73 0.67	0.89 0.73 0.67	0.88 0.75 0.67	0.87 0.72 0.63	0.89 0.65 0.61	0.90 0.70 0.71	0.89 0.71 0.66
ABT-263	0.83 0.67 0.68	0.81 0.71 0.67	0.83 0.66 0.55	0.81 0.69 0.67	0.79 0.65 0.64	0.79 0.65 0.59	0.81 0.67 0.63
GSK1070916	0.94 0.71 0.70	0.92 0.74 0.67	0.94 0.71 0.52	0.95 0.77 0.71	0.92 0.61 0.57	0.91 0.59 0.59	0.93 0.69 0.63
Methotrexate	0.81 0.38 0.58	0.81 0.42 0.55	0.82 0.41 0.23	0.81 0.31 0.58	0.83 0.32 0.61	0.80 0.31 0.54	0.81 0.36 0.52
TL-1-85	0.95 0.63 0.65	0.91 0.49 0.57	0.95 0.72 0.57	0.92 0.49 0.62	0.93 0.56 0.67	0.91 0.61 0.52	0.93 0.58 0.6
T0901317	0.88 0.62 0.67	0.87 0.71 0.57	0.88 0.61 0.67	0.88 0.71 0.65	0.87 0.60 0.58	0.88 0.57 0.59	0.88 0.64 0.62
PHA-793887	0.98 0.69 0.55	0.97 0.48 0.56	0.97 0.60 0.60	0.97 0.53 0.63	0.99 0.87 0.50	0.99 0.84 0.52	0.98 0.67 0.56
JW-7-24-1	0.90 0.55 0.62	0.90 0.48 0.54	0.91 0.56 0.56	0.90 0.55 0.63	0.89 0.42 0.53	0.88 0.52 0.44	0.9 0.51 0.55
TPCA-1	0.95 0.69 0.55	0.94 0.60 0.52	0.95 0.60 0.38	0.95 0.65 0.50	0.94 0.66 0.52	0.94 0.69 0.53	0.94 0.65 0.5
CX-5461	0.64 0.73 0.70	0.70 0.77 0.73	0.68 0.75 0.72	0.67 0.75 0.72	0.63 0.70 0.73	0.63 0.73 0.72	0.66 0.74 0.72
STF-62247	0.77 0.52 0.54	0.78 0.58 0.51	0.71 0.53 0.54	0.77 0.59 0.54	0.71 0.43 0.47	0.72 0.44 0.48	0.74 0.52 0.51
Dabrafenib	0.65 0.23 0.29	0.70 0.31 0.32	0.66 0.24 0.28	0.69 0.26 0.24	0.67 0.22 0.29	0.65 0.20 0.26	0.67 0.24 0.28
GSK429286A	0.89 0.69 0.65	0.87 0.65 0.61	0.86 0.62 0.63	0.88 0.70 0.65	0.87 0.59 0.60	0.88 0.64 0.58	0.88 0.65 0.62
Trametinib	0.79 0.62 0.62	0.78 0.69 0.60	0.80 0.72 0.61	0.80 0.70 0.61	0.80 0.70 0.62	0.79 0.69 0.66	0.79 0.69 0.62
NG-25	0.93 0.66 0.64	0.85 0.55 0.64	0.95 0.73 0.55	0.93 0.69 0.55	0.93 0.78 0.67	0.95 0.80 0.73	0.92 0.7 0.63
BIX02189	0.94 0.70 0.82	0.94 0.68 0.59	0.93 0.67 0.71	0.93 0.63 0.71	0.96 0.79 0.76	0.95 0.77 0.83	0.94 0.71 0.74
PIK-93	0.84 0.75 0.67	0.81 0.60 0.67	0.82 0.68 0.64	0.86 0.77 0.67	0.83 0.66 0.62	0.82 0.61 0.64	0.83 0.68 0.65
XMD15-27	0.96 0.86 0.76	0.95 0.86 0.76	0.92 0.87 0.78	0.94 0.81 0.69	0.93 0.71 0.71	0.93 0.80 0.60	0.95 0.81 0.72
AC220	0.83 0.47 0.36	0.78 0.36 0.41	0.80 0.46 0.45	0.81 0.45 0.40	0.82 0.48 0.42	0.83 0.46 0.39	0.81 0.45 0.4
Media modello	0.85 0.63 0.6	0.84 0.61 0.58	0.85 0.64 0.57	0.85 0.63 0.59	0.84 0.58 0.57	0.84 0.59 0.56	

Figura 2.5 Risultati per ogni farmaco relativi a AUC ROC curve (rosso), AUC PR (verde) e F1-score (blu).

2.3.4 IC_{50} e Sensibilità

Il modello per predire l' IC_{50} e la *sensibilità* sviluppato per ogni farmaco è un regressore che predice inizialmente solamente l' IC_{50} (valore continuo) basandosi sempre su un approccio ensemble come descritto nel paragrafo 2.3.3. Dopo aver stimato tale valore ,con la media dell' IC_{50} predetto da ciascun modello , viene stabilita una soglia di IC_{50} (non di probabilità) , sempre determinata in modo tale da massimizzare l'*f1-score* nel validation set, sotto la quale la linea cellulare viene predetta sensibile [2.6]. Infine, come sopra, sono stati realizzati diversi grafici con lo scopo di poter modificare tale soglia a seconda delle necessità, quindi privilegiare la *precision* o la *recall*.

Analogamente a quanto fatto per il primo modello, è stato effettuato un hyperparameter tuning con la libreria *optuna*⁽¹⁰⁾ ma questa volta con l'obiettivo di massimizzare l' R^2 sul 30° percentile più basso. Questa potrebbe sembrare una scelta particolare, ma come ripetuto più volte l'obiettivo principale è quello di determinare se una linea cellulare è sensibile e così facendo si privilegia il fatto che queste siano il più possibile in "ordine" (R^2),dalla più sensibile alla più resistente e maggiormente performanti soprattutto nella parte inferiore (30° percentile)




Figura 2.6 In questa figura viene mostrato come viene calcolata la threshold dalla AUC-PR curve


Ai grafici realizzati prima per ogni farmaco, verrà inoltre aggiunto quello relativo alla relazione tra IC_{50} reale e quello predetto [2.8].

Infine, come anticipato nel paragrafo relativo al preprocessing, l' IC_{50} segue una distribuzione normale ma noi siamo maggiormente interessati ai valori relativi alla classe dei sensibili (IC_{50} più bassi). Per questo, due approcci distinti sono stati sviluppati allo scopo di confrontarne l'efficacia: il primo non applica alcuna tecnica di oversampling, mentre il secondo prevede la generazione di esempi sintetici per la classe minoritaria.

Primo approccio, senza oversampling

Questo modello non prevede alcuna tecnica di oversampling, come fatto nella letteratura da tutti gli articoli che affrontano questo tema, tra cui quello preso come riferimento e più volte citato⁽³⁾.

Nella tabella 2.7 vengono presentati i risultati relativi a tutti i farmaci considerando sia le metriche relative alla sensibilità che quelle relative all' IC_{50} (R^2 e Coefficiente di Pearson (r)) per i modelli descritti nella prima tabella ma ovviamente stavolta presi come regressori e non classificatori.



Secondo approccio, utilizzo dell' oversampling

Nel secondo approccio, invece, viene applicato nella parte di training l'oversampling nel seguente modo:

- **SMOTE sulla classe di sensibili:** Viene prima applicato l'oversampling sulla classe dei sensibili sul training set al fine di bilanciare le due classi.
- **Assegnazione del valore di IC_{50} :** Successivamente, viene utilizzato un regressore k-NN addestrato sui dati originali per stimare il valore di IC_{50} associato agli esempi sintetici generati da SMOTE.

Nella tabella 2.11 vengono presentati i risultati relativi a tutti i farmaci considerando sia le metriche relative alla sensibilità che quelle relative all' IC_{50} (R^2 e Coefficiente di Pearson (r)) per i modelli già descritti sopra.




Figura 2.8 Confronto IC_{50} reale e predetto




Figura 2.9 Confusion Matrix




Figura 2.10 Precision and Recall curve

Trametinib

Si osserva come i modelli sviluppati sul farmaco, Trametinib, raggiungano qui un f1-score tra 0.58 e 0.66 nei modelli che utilizzano il primo approccio, mentre tra 0.61 e 0.67 in quelli che utilizzano il secondo.

In particolare, *GB XGB RF* e *CNN* sembrano essere i modelli che funzionano meglio nella predizione, raggiungendo entrambi un F1-score di ≈ 0.67 . Nello specifico, nella figura 2.6, 2.8, 2.9 e 2.10 vengono raffigurati i risultati con il modello *GB XGB RF*.

Considerazioni sui modelli

Sulle linee cellulari i modelli raggiungono performance molto simili tra loro poiché, in effetti, hanno ciascuno dei limiti e punti di forza, come riassunto nella tabella 2.1

	R2		ROC AUC		F1-score		Pearson_coeff		PR AUC					
	RF_IC50		XGB_IC50		GB_IC50		GB_XGB_RF		mlp		cnn		Drug's mean	
KIN001-260	0.31 0.74	0.56 0.59	0.27 0.73	0.55 0.59	0.24 0.73	0.55 0.57	0.28 0.71	0.53 0.55	0.18 0.50	0.52 0.73	0.11 0.47	0.53 0.76	0.23 0.65	0.54 0.63
	0.48		0.51		0.51		0.52		0.46		0.51		0.5	
TG101348	0.31 0.92	0.58 0.75	0.06 0.95	0.58 0.77	0.13 0.94	0.58 0.75	0.35 0.92	0.60 0.75	0.17 0.62	0.55 0.93	0.08 0.67	0.52 0.90	0.18 0.84	0.57 0.81
	0.73		0.67		0.67		0.67		0.70		0.65		0.68	
BX-912	0.50 0.94	0.72 0.67	0.21 0.94	0.66 0.68	0.38 0.93	0.71 0.69	0.52 0.95	0.72 0.70	0.16 0.67	0.70 0.90	0.16 0.69	0.69 0.90	0.32 0.85	0.7 0.76
	0.76		0.71		0.73		0.67		0.71		0.71		0.72	
QL-XI-92	0.32 0.78	0.63 0.66	0.34 0.75	0.62 0.63	0.36 0.77	0.63 0.66	0.33 0.76	0.62 0.63	0.34 0.59	0.59 0.76	0.34 0.56	0.60 0.75	0.34 0.7	0.62 0.68
	0.61		0.61		0.57		0.56		0.55		0.60		0.58	
Tubastatin A	0.40 0.75	0.64 0.64	0.40 0.74	0.64 0.65	0.35 0.73	0.63 0.63	0.40 0.70	0.63 0.62	0.31 0.51	0.59 0.69	0.12 0.46	0.52 0.68	0.33 0.65	0.61 0.65
	0.53		0.52		0.53		0.49		0.59		0.53		0.53	
GSK690693	0.35 0.72	0.60 0.66	0.34 0.73	0.59 0.64	0.32 0.71	0.58 0.64	0.37 0.73	0.61 0.66	0.25 0.57	0.52 0.69	0.22 0.55	0.52 0.69	0.31 0.67	0.57 0.66
	0.57		0.54		0.55		0.55		0.60		0.60		0.57	
XMD14-99	0.18 0.84	0.46 0.40	0.14 0.85	0.45 0.37	0.19 0.84	0.48 0.42	0.15 0.80	0.47 0.36	0.11 0.44	0.49 0.85	-0.10 0.44	0.49 0.86	0.11 0.7	0.47 0.54
	0.47		0.46		0.47		0.50		0.45		0.42		0.46	
NPK76-II-72-1	0.37 0.96	0.61 0.71	0.01 0.97	0.60 0.69	0.15 0.96	0.61 0.70	0.34 0.96	0.58 0.64	-0.08 0.58	0.61 0.96	-0.15 0.60	0.60 0.94	0.11 0.84	0.6 0.77
	0.61		0.56		0.62		0.38		0.60		0.46		0.54	
Y-39983	0.28 0.81	0.55 0.77	0.27 0.79	0.53 0.74	0.27 0.80	0.53 0.76	0.27 0.79	0.53 0.76	0.28 0.55	0.53 0.73	0.26 0.55	0.52 0.72	0.27 0.72	0.53 0.75
	0.67		0.64		0.63		0.66		0.66		0.69		0.66	
AT-7519	0.11 0.96	0.35 0.36	-0.47 0.97	0.34 0.42	-0.12 0.96	0.36 0.37	0.13 0.96	0.37 0.37	-0.49 0.44	0.34 0.96	-0.51 0.40	0.34 0.96	-0.22 0.78	0.35 0.57
	0.00		0.50		0.44		0.25		0.40		0.39		0.33	
KIN001-236	0.33 0.80	0.58 0.66	0.13 0.79	0.57 0.53	0.15 0.79	0.59 0.60	0.30 0.79	0.56 0.59	-0.03 0.58	0.57 0.79	-0.02 0.59	0.57 0.81	0.14 0.72	0.57 0.66
	0.60		0.62		0.62		0.56		0.53		0.50		0.57	
TL-2-105	0.41 0.90	0.66 0.75	0.28 0.84	0.64 0.61	0.30 0.88	0.67 0.68	0.44 0.89	0.67 0.65	0.25 0.64	0.62 0.90	0.19 0.65	0.56 0.88	0.31 0.8	0.64 0.74
	0.74		0.67		0.67		0.50		0.68		0.61		0.64	
ABT-263	0.28 0.81	0.60 0.66	0.27 0.79	0.61 0.68	0.22 0.80	0.61 0.64	0.31 0.77	0.58 0.67	0.27 0.65	0.53 0.78	0.26 0.61	0.54 0.78	0.27 0.74	0.58 0.7
	0.65		0.69		0.67		0.64		0.63		0.64		0.65	
GSK1070916	0.43 0.94	0.73 0.74	0.39 0.92	0.69 0.69	0.30 0.92	0.69 0.69	0.40 0.92	0.68 0.69	0.42 0.60	0.68 0.93	0.35 0.54	0.69 0.94	0.38 0.81	0.69 0.78
	0.64		0.55		0.58		0.56		0.69		0.71		0.62	
Methotrexate	0.27 0.83	0.57 0.35	-0.02 0.84	0.58 0.35	0.06 0.84	0.58 0.35	0.33 0.87	0.60 0.37	0.09 0.61	0.57 0.84	0.09 0.58	0.53 0.83	0.14 0.76	0.57 0.52
	0.55		0.56		0.58		0.64		0.36		0.34		0.5	
TL-1-85	0.41 0.93	0.64 0.58	0.17 0.92	0.64 0.55	0.29 0.92	0.60 0.54	0.44 0.91	0.67 0.54	0.04 0.65	0.62 0.93	0.05 0.67	0.58 0.93	0.23 0.83	0.62 0.68
	0.62		0.65		0.61		0.60		0.62		0.69		0.63	
T0901317	0.27 0.84	0.56 0.51	-0.05 0.81	0.51 0.69	-0.06 0.83	0.54 0.49	0.22 0.80	0.50 0.64	0.15 0.65	0.49 0.84	0.07 0.58	0.49 0.82	0.1 0.75	0.52 0.66
	0.58		0.61		0.62		0.67		0.50		0.43		0.57	
PHA-793887	0.18 0.98	0.48 0.76	-0.26 0.98	0.49 0.78	-0.22 0.98	0.47 0.74	0.19 0.98	0.49 0.59	0.10 0.52	0.49 0.98	0.01 0.52	0.48 0.99	-0.0 0.83	0.48 0.81
	0.57		0.57		0.50		0.55		0.64		0.77		0.6	
JW-7-24-1	0.28 0.92	0.56 0.59	0.06 0.90	0.52 0.48	0.09 0.92	0.56 0.53	0.28 0.92	0.56 0.53	0.21 0.57	0.56 0.90	0.27 0.59	0.57 0.90	0.2 0.8	0.56 0.65
	0.59		0.62		0.57		0.53		0.46		0.56		0.55	
TPCA-1	0.32 0.96	0.62 0.74	-0.06 0.95	0.62 0.67	0.01 0.95	0.63 0.74	0.34 0.95	0.61 0.64	0.27 0.60	0.58 0.95	0.19 0.60	0.55 0.94	0.18 0.83	0.6 0.78
	0.50		0.58		0.53		0.58		0.63		0.63		0.57	
CX-5461	0.23 0.62	0.50 0.72	0.18 0.61	0.44 0.69	0.24 0.66	0.49 0.71	0.22 0.64	0.48 0.71	0.19 0.72	0.44 0.65	0.16 0.71	0.47 0.67	0.2 0.66	0.47 0.69
	0.73		0.73		0.75		0.72		0.73		0.75		0.74	
STF-62247	0.29 0.68	0.56 0.46	0.09 0.67	0.54 0.45	0.08 0.67	0.55 0.46	0.30 0.69	0.55 0.45	0.12 0.49	0.51 0.65	0.12 0.50	0.52 0.68	0.17 0.62	0.54 0.52
	0.49		0.50		0.51		0.50		0.39		0.42		0.47	
Dabrafenib	0.14 0.60	0.42 0.32	0.19 0.68	0.46 0.35	0.18 0.65	0.45 0.32	0.17 0.61	0.45 0.34	-0.08 0.28	0.36 0.65	-0.17 0.27	0.36 0.69	0.07 0.52	0.42 0.44
	0.26		0.29		0.29		0.27		0.27		0.25		0.27	
GSK429286A	0.35 0.90	0.65 0.66	0.11 0.89	0.65 0.65	0.16 0.87	0.65 0.61	0.40 0.92	0.65 0.66	0.30 0.62	0.64 0.87	0.22 0.60	0.61 0.86	0.26 0.8	0.64 0.72
	0.58		0.58		0.54		0.64		0.55		0.56		0.57	
Trametinib	0.21 0.77	0.47 0.65	0.22 0.78	0.48 0.68	0.22 0.78	0.48 0.63	0.22 0.78	0.47 0.64	0.21 0.59	0.55 0.77	0.17 0.57	0.53 0.78	0.21 0.71	0.5 0.69
	0.61		0.62		0.65		0.67		0.66		0.67		0.65	
NG-25	0.39 0.93	0.64 0.71	0.24 0.91	0.60 0.66	0.29 0.91	0.62 0.60	0.37 0.90	0.61 0.59	0.16 0.74	0.62 0.90	0.08 0.69	0.61 0.94	0.26 0.85	0.62 0.73
	0.69		0.62		0.54		0.45		0.73		0.65		0.61	
BIX02189	0.40 0.95	0.66 0.70	-0.05 0.93	0.64 0.67	0.12 0.95	0.65 0.71	0.39 0.94	0.64 0.64	0.15 0.80	0.66 0.96	0.12 0.79	0.67 0.95	0.19 0.89	0.65 0.77
	0.79		0.79		0.77		0.57		0.73		0.76		0.74	
PIK-93	0.22 0.77	0.57 0.59	-0.15 0.81	0.56 0.68	-0.10 0.80	0.55 0.68	0.23 0.81	0.55 0.75	0.26 0.64	0.58 0.83	0.22 0.60	0.55 0.80	0.11 0.74	0.56 0.72
	0.72		0.58		0.58		0.60		0.60		0.62		0.62	
XMD15-27	0.40 0.94	0.67 0.81	0.17 0.94	0.68 0.82	0.19 0.94	0.67 0.83	0.45 0.93	0.69 0.84	0.19 0.76	0.60 0.92	0.14 0.80	0.64 0.94	0.26 0.88	0.66 0.86
	0.72		0.73		0.77		0.76		0.86		0.87		0.78	
AC220	0.31 0.83	0.59 0.41	0.16 0.82	0.55 0.36	0.25 0.84	0.59 0.41	0.32 0.82	0.59 0.37	0.20 0.38	0.53 0.83	0.17 0.49	0.54 0.83	0.24 0.7	0.56 0.54
	0.38		0.39		0.38		0.41		0.43		0.48		0.41	
Model's mean	0.31 0.84	0.58 0.62	0.12 0.84	0.57 0.61	0.17 0.84	0.58 0.6	0.32 0.84	0.58 0.6	0.16 0.59	0.55 0.84	0.11 0.58	0.55 0.84	0.23 0.65	0.54 0.63
	0.58		0.59		0.58		0.56		0.58		0.58			

Figura 2.11 Risultati per ogni farmaco relativi a R^2 (rosso), coefficiente di Pearson (verde) AUC ROC curve (blu), AUC PR (arancione) e F1-score (viola) con secondo approccio.

Modello	Punti di forza	Limiti
Classificazione	Affronta il problema come classificazione e bilancia le classi	Non tiene in considerazione l'IC50
Regressione I	Utilizza l'IC50	Non affronta problema come classificazione e le classi sono sbilanciate
Regressione II	Utilizza l'IC50 e bilancia le classi	Non affronta problema come classificazione

Tabella 2.1 Confronto tra tre modelli con relativi limiti e punti di forza

2.4 Interpretabilità dei modelli

Come detto nell'introduzione, è di fondamentale importanza capire il motivo per cui i modelli ritornino un dato risultato per poter formulare ipotesi meccanicistiche sulla risposta ai farmaci. A tal scopo, per ogni modello sono stati individuati attraverso l'algoritmo *Lime*⁽²⁾, le *features* che hanno influenzato maggiormente la risposta. Nello specifico, quest'analisi sarà diversa da quella degli articoli simili in letteratura che affrontavano lo stesso tema perchè si andrà a focalizzare sui *fattori di trascrizione* e non sui *geni*. Inoltre, è da evidenziare che l'uso dei modelli ensemble potrebbe essere utile per una maggiore robustezza dell'interpretabilità delle risposte ai farmaci.

Le features più importanti sono state dunque individuate attraverso le rappresentazioni SHAP, che sono state generate per ciascun farmaco e per ognuno dei sei modelli utilizzati. Le rappresentazioni SHAP sono state generate sia a livello locale, considerando ogni singola combinazione farmaco–linea cellulare [2.12], che a livello globale, aggregando l'importanza delle features sull'intero dataset per ottenere i *SHAP summary plots* [2.13]. Questi raffigurano come le variazioni nell'attivazione dei 10 fattori di trascrizione più rilevanti per il farmaco determinino la sensibilità su ogni cellula. Ad esempio, per quanto riguarda le rappresentazioni a livello locale, si può notare che secondo il modello per il farmaco Fedratinib nelle cellule di melanoma A2058, il fattore TBX21 è associato alla resistenza al farmaco, mentre HOXA13 alla sensibilità [2.12].







Figura 2.12 Spiegazione SHAP esemplificativa sulla singola linea cellulare per un determinato farmaco. Si possono osservare in rosso i 5 fattori di trascrizione che spostano maggiormente la decisione del modello per la singola linea cellulare verso la resistenza ed in blu verso la sensibilità. Nella figura a) si nota l'interazione tra la cellula A2058 e il Fedratinib e nella b) tra la cellula A375 e il Trametinib.




(1)




(2)




(3)




(4)




(5)




(6)




(7)




(8)




(9)




(10)




(11)




(12)



(13)



(14)



(15)




Figura 2.13 Spiegazione SHAP per ciascuno dei 30 farmaci

Per determinare i biomarcatori per il summary plot, invece, è stata calcolata la media assoluta dei valori SHAP ottenuti dai singoli modelli, ricavando i risultati mostrati nella figura 2.13.

Inoltre, come già osservato, i risultati sono molto simili tra loro e per questo motivo, nelle figure 2.13 sono illustrati solo quelli relativi al modello XGBoost come regressore (sia il primo che il secondo approccio), in quanto questo è il migliore in termini di ottimizzazione per SHAP nell'efficienza computazionale e nella migliore interpretabilità. Infine, per ciascun farmaco, nella scelta tra i due approcci di regressione è stato selezionato il modello con le migliori performance.

Nella figura 2.13 sono dunque rappresentati i 30 farmaci con i rispettivi *SHAP summary plots* e per ognuno vengono descritti i fattori di trascrizione con il maggiore impatto sul farmaco, indicati sull'asse y. Ogni punto corrisponde a una linea cellulare ed è colorato in blu se il corrispondente fattore di trascrizione è sotto attivato, mentre in rosso se questo è sovra attivato, con il relativo valore SHAP indicato sull'asse x. Quest'ultimo, in particolare, sarà positivo se il fattore di trascrizione relativo alla corrispondente linea cellulare sposterà la decisione del modello sulla sensibilità e negativo al contrario.

Per questioni di tempo e spazio, non andremo a presentare tutti i farmaci con la loro *explainability*, ma solo quelli che sono discussi nella tesi, ovvero il *Trametinib* e il *Fedratinib*.

Fedratinib

Il *Fedratinib* è un farmaco che agisce bloccando la proteina JAK2, un enzima chiave nella via di segnalazione JAK/STAT, spesso iperattivata nelle malattie del sangue, come la mielofibrosi, rallentando la crescita delle cellule tumorali⁽¹¹⁾.

La figura 2.13.2 illustra i 10 fattori di trascrizione più rilevanti nel modello e si può notare come questa sia effettivamente interpretabile a livello biologico. In particolare, si può notare come molti fattori siano regolati indirettamente dalla via menzionata prima. In particolare, tra i primi 5 fattori, si possono osservare:

- **TBX21** La relazione tra questo fattore e il suo ruolo nella via di segnalazione in questione è particolarmente presente nella letteratura sia a livello di pathway biologici⁽¹²⁾ che da analisi compiute sui pazienti con melanoma cutaneo⁽¹³⁾
- **RUNX1 e RUNX2** Questi due fattori di trascrizione sono molto interessanti perchè, pur appartenendo alla stessa famiglia RUNX, sembrano svolgere ruoli opposti [2.13.2]. In particolare, l'up regolazione di RUNX1 è associata ad una maggiore sensibilità per questo farmaco e al contrario la down-regolazione ad una maggiore resistenza. Inoltre, molti articoli sottolineano l'importanza in relazione alla via di segnalazione JAK/STAT di questa famiglia di fattori tra cui⁽¹⁴⁾.
- **SPI1** Anche questo fattore è molto citato in letteratura⁽¹⁵⁾ in relazione alla via di segnalazione JAK/STAT. In particolare, la figura 2.13.2 mostra in maniera netta come la sovraregolazione di questo biomarcatore sia legata ad una maggiore sensibilità a questo farmaco.
- **PGR** è un recettore-fattore di trascrizione, attivato dal progesterone. Questo fattore di trascrizione non è direttamente legato alla via di segnalazione di questo farmaco, ma come spiegato più avanti sembra assumere in alcune cellule una particolare importanza nella previsione della sensibilità.

Trametinib

Il *Trametinib* è un farmaco che agisce bloccando la proteina MEK, fondamentale nella via di segnalazione MAPK/ERK, spesso iperattivata nei tumori con mutazione del gene BRAF, rallentando la crescita delle cellule tumorali⁽¹⁶⁾.

La figura 2.13.25 illustra i 10 fattori di trascrizione più rilevanti nel modello e si può notare come anche questo sia effettivamente interpretabile a livello biologico. Nello specifico si può notare come i fattori di trascrizione *TFAP2A* e *JUN* siano i biomarcatori più rilevanti nella predizione alla risposta al trattamento. In particolare, *JUN* è direttamente legato all'azione del farmaco in quanto si trova a valle della via di segnalazione MAPK/ERK e ne riflette l'attivazione. Inoltre, alcuni studi suggeriscono come anche *TFAP2A* sia fortemente legato all'attività di questa via e quindi all'efficacia di questo farmaco. L'articolo⁽¹⁷⁾, infatti, sostiene che in determinate linee cellulari la sovraespressione di questo biomcatore rifletta la sovraattivazione di questa via.

Conclusioni

Dall'analisi condotta emerge che i modelli di predizione di risposta ai farmaci descritti sono interpretabili e coerenti a livello biologico. E' importante ribadire che queste analisi permettono di formulare ipotesi meccanicistiche sulla relazione tra attività dei fattori di trascrizione e risposte a specifici trattamenti, offrendo l'opportunità di scoprirne di nuovi. Questo è ovviamente maggiormente valido nei modelli le cui performance sono migliori, in quanto in questi casi anche l'interpretabilità sarà più forte.

Infine, osservando i 30 grafici SHAP, si può notare come nella maggior parte di essi il *PGR* sia tra i fattori di trascrizione più importanti. Questo può essere molto interessante perchè, nonostante i modelli siano stati ideati in modo indipendente su farmaci diversi, questo fattore di trascrizione sembra ricoprire quasi sempre un ruolo cruciale. Nello specifico, in tutti i casi, la sottoespressione in alcune linee cellulari sembra essere correlata con una maggiore sensibilità ai vari farmaci. Questa osservazione, infatti, può essere utile nello sviluppare nuovi farmaci in quanto si potrebbe dare maggiore importanza a questo fattore di trascrizione.

Capitolo 3

Pazienti

L'obiettivo dell'ultimo capitolo è quello di applicare i modelli sviluppati sulle linee cellulari ai pazienti. Purtroppo, come già detto nell'introduzione, non si possono testare i farmaci sui pazienti e per questo motivo, i dati disponibili sugli esseri umani sono quasi nulli.

In effetti, tra i 30 farmaci su cui sono stati applicati i modelli solo sul *Fedratinib* (TG101348) e sul *Methotrexate* sono stati individuati dei dati. Per questione di tempo, in questo paragrafo è stato scelto di trattare solo il Fedratinib in quanto è quello che aveva raggiunto risultati decisamente migliori nelle cellule in vitro con i diversi approcci [2.5, 2.7 e 2.11].

3.0.1 Fedratinib

Preprocessing

I dati di espressione genica del benchmarking del modello sono stati scaricati dal database GEO e fanno riferimento ad una corte di 15 pazienti affetti dalla leucemia mieloide acuta (AML). In questa prima fase, è stato applicato lo stesso preprocessing effettuato nelle cellule in vitro. In particolare, per ogni paziente è stato rilevato il profilo trascrittomico (espressione genica) e la corrispondente risposta al farmaco (classificata come *Responder*, *Partial Responder* e *Non Responder*). Successivamente, sono stati sia integrati i dataset relativi alla trascrittomica ed al drug screening dei pazienti che attuate le stesse trasformazioni effettuate per l'espressione genica delle linee cellulari descritte nel capitolo 2.1.1. Infine, attraverso l'utilizzo di SignalingProfiler, è stata inferita l'attività dei fattori di trascrizione a partire dai dati di espressione genica.

Analisi delle risposte dei Pazienti

Il numero di pazienti disponibili su cui il farmaco è stato testato sono solo 15, di cui 8 *Responder*, 4 *Partial Responder* e solo 3 *Non Responder*. In particolare i *Responder* ed i *Partial Responder* sono stati considerati sensibili al farmaco e gli altri resistenti. Tuttavia, come possiamo notare, la distribuzione dei dati è completamente opposta a quella del dataset delle cellule in vitro nella quale solo il 10% erano sensibili. Questo però non ci deve troppo stupire poiché il farmaco, per essere stato utilizzato per il trattamento di esseri umani, aveva sicuramente delle evidenze biologiche che portavano a pensare che i pazienti potessero rispondere in maniera positiva. Nonostante ciò, ovviamente, questo non corrispondeva sempre a verità in quanto nei pazienti, come più volte ripetuto, sono coinvolti dei fattori esterni non prevedibili nelle linee cellulari e su cui i modelli non possono essere allenati. Per questo motivo, l'obiettivo realistico di quest'analisi non è tanto quello di prevedere perfettamente la risposta clinica di ogni singolo paziente ma quello di individuare il maggior numero possibile


di pazienti sensibili (valore di IC_{50} inferiore alla soglia definita durante il training). Infatti, è importante sottolineare che è impossibile prevedere accuratamente effetti o variabili non presenti nei dati di partenza e su cui quindi il modello non è stato addestrato.


Modelli e risultati

Ogni paziente è stato testato utilizzando i diversi modelli ottenuti con i tre diversi approcci e i risultati sono molto soddisfacenti in quanto nella maggior parte dei modelli questi pazienti vengono predetti come sensibili. Questo, come detto, non è assolutamente scontato in quanto il modello nei dati di training era stato allenato su linee cellulari prevalentemente resistenti ed il fatto che riesca ad individuare la risposta positiva nei pazienti è sintomo che sta cogliendo i giusti segnali biologici. Infine, è da evidenziare che l'approccio che funziona meglio sui pazienti è quello con il regressore che utilizza l'oversampling. Infatti, qui tutti e 6 i modelli predicono i pazienti come sensibili tranne RF (che predice erroneamente un solo resistente).

Explainability

Successivamente, come fatto per le linee cellulari, per ogni paziente sono stati calcolati i fattori di trascrizione che hanno maggiormente influenzato la risposta al farmaco. Nelle figure seguenti 3.1, a differenza di prima, illustreremo tutte le interpretazioni per ciascun paziente relative alla risposta al farmaco in quanto sono solo 15. Inoltre, quest'analisi verrà effettuata, come per le linee cellulari, solo per il modello XGB utilizzando il secondo approccio (oversampling).





(15)

Figura 3.1 Spiegazione SHAP per ciascuno paziente. In particolare, vengono illustrati i top 5 farmaci che spostano il modello verso la sensibilità (blu) e i top 5 che lo spostano verso la resistenza (rosso)

Quest'analisi è molto interessante in quanto ci si focalizza solo sui pazienti con caratteristiche in comune e considerati sensibili al farmaco. Nello specifico, in linea con i risultati, si può osservare come il valore SHAP relativo ai fattori di trascrizione che muovono il modello verso la sensibilità sia in valore assoluto molto più alto rispetto a quelli che lo dirigono verso la resistenza. Inoltre, si può notare come i fattori di trascrizione *RUNX1* e *TBX21*, già citati ed osservati nel modello con i dati delle linee cellulari, siano anche qua i più rilevanti in quanto compaiono in tutti i grafici e quasi sempre anche tra i primi due biomarcatori più importanti per la sensibilità. Infine, si possono registrare sia alcuni biomarcatori, non rilevati nelle linee cellulari, molto presenti come *GATA2* e sia altri riscontrati nelle cellule in vitro non individuati in questi pazienti come *SPI1* e *PGR*. Tuttavia questo è assolutamente normale poichè quello che è stato analizzato, come già ripetuto, è un sottoinsieme specifico di una popolazione con profili genomici simili e la particolarità di essere sensibili ai farmaci.

Capitolo 4

Discussione

4.0.1 Discussione

Questa tesi e i rispettivi modelli implementati si propongono come strumenti per affrontare il problema oggi cruciale delle cure specializzate per i pazienti che, come detto nell'introduzione, sono fondamentali a causa dell'eterogeneità dei tumori.

I modelli hanno raggiunto dei buoni risultati nelle cellule in vitro. Tuttavia, è difficile pensare di poter predire la sensibilità di un farmaco affidandosi solo a questi in quanto, a causa della mancanza di disponibilità di dati e della complessità del segnale biologico, non rappresentano previsioni inconfutabili. Nonostante questo, ritengo che le interpretazioni dei modelli attraverso *SHAP* siano cruciali poiché offrono una prospettiva diversa rispetto ad articoli presenti in letteratura e perché possono far scoprire delle relazioni nuove tra biomarcatori e farmaci o confermare quelle passate. In effetti, ci tengo ad evidenziare che, poiché i modelli performano molto meglio rispetto a un classificatore baseline [2.3.1], queste relazioni sono effettivamente presenti nei dati. Inoltre, l'utilizzo di questi modelli permette anche di osservare correlazioni non lineari o che riguardano solo un determinato numero di linee cellulari o individui.

Per quanto riguarda l'affidabilità di questi modelli, invece, si è osservato che questi possono essere trasferiti e applicati anche nei pazienti, raggiungendo buoni risultati. Tuttavia, è fondamentale rimarcare che rimangono delle limitazioni dovute al fatto che le cellule in vitro siano solo delle rappresentazioni delle malattie e per questo motivo è impossibile pensare di tenere in considerazione fattori esterni propri dei pazienti non rappresentati nelle linee cellulari.

Infine, in questa tesi non sono state analizzate per ogni farmaco le linee cellulari per tessuti specifici per mancanza di tempo e spazio, ma se si vuole compiere uno studio specifico per un farmaco sarebbe interessante farlo sia per individuare quali di questi tessuti hanno performance migliori e sono più affidabili come fatto nell'articolo⁽³⁾ ma anche per comprenderne i biomarcatori più rilevanti per quel sottoinsieme di linee cellulari o pazienti come fatto nel paragrafo 3.0.1.

4.0.2 Metodi

Preprocessing dei Dati per le cellule in vitro

Per il preprocessing dei dati è stato utilizzato RStudio⁽¹⁸⁾ ed i dati sono stati reperiti da GDSC⁽⁸⁾ per il drug screening e CCLE⁽⁷⁾ per la trascrittomica. Successivamente sono state applicate le seguenti trasformazioni (descritte in maniera più approfondita nel paragrafo 2.1) e i cui codici sono reperibili su Github nella cartella Preprocessing/Gene_expression_Sign:

- Pulizia Drug Screening rimuovendo le righe con IC_{50} o sensibilità nulle (Drug_screening_cleaned.R).
- Per la trascrittomica è stata effettuata un'aggregazione per gene, sono stati poi considerati solo i geni codificanti ai quali è stata applicata una trasformazione logaritmica e una normalizzazione tramite z-score (transc_harmonization.R).
- Trasformazione dall'espressione genica ai fattori di trascrizione includendo solo quelli con aumento un gene significativo. (Preprocessing_transcriptomic.R)
- Integrazione dei due Dataset (Trascrittomica e Drug Screening) (mix_tables.R)

Preprocessing Pazienti

I dati relativi ai pazienti sul farmaco *Fedratinib* sono stati reperiti da GEO e sono disponibili nella cartella pazienti di Github insieme ai relativi codici per il preprocessing, il quale segue la stessa struttura delle cellule in vitro.

Drug Selector

Per i 216 farmaci è stato applicato, come descritto nel capitolo 2.2, un selezionatore di farmaci basato sul modello RF, implementato con Python⁽¹⁹⁾, il quale può essere reperibile nella cartella Preprocessing/Dataset Cleaning and Drug Selector.ipynb

Modelli e risultati

I 30 migliori modelli ottenuti dal selezionatore di farmaci sono stati riallenati su ogni farmaco per ogni fold, come descritto nel paragrafo 2.3, con Python⁽¹⁹⁾ e sono reperibili nei vari file DL models.ipynb, IC50_ML.ipynb e Sensitivity_ML.ipynb. Per ognuno di essi è stato effettuato l'HyperParameter Tuning con la libreria Optuna⁽¹⁰⁾ sugli iperparametri già descritti nel paragrafo 2.3.2, sono stati generati i grafici, calcolate le metriche e sono state implementate le corrispettive rappresentazioni SHAP⁽²⁾. Successivamente, i modelli ottenuti sono stati testati sui pazienti trattati con il farmaco *Trametinib* test_patients.ipynb, generando i relativi grafici e le corrispettive rappresentazioni SHAP⁽²⁾. Infine, tutti i risultati, anche quelli non discussi direttamente nella tesi, relativi sia alle cellule in vitro che ai pazienti, sono disponibili in Results.

Bibliografia

- [1] Veronica Venafrà, Francesca Sacco, and Livia Perfetto. Signalingprofiler 2.0 a network-based approach to bridge multi-omics data to phenotypic hallmarks. *npj Systems Biology and Applications*, 10(1), August 2024. ISSN 2056-7189. doi: 10.1038/s41540-024-00417-6. URL <http://dx.doi.org/10.1038/s41540-024-00417-6>.
- [2] Ahmed Salih, Zahra Raisi-Estabragh, Ilaria Boscolo Galazzo, Petia Radeva, Steffen E. Petersen, Gloria Menegaz, and Karim Lekadir. A perspective on explainable artificial intelligence methods: Shap and lime. 2023. doi: 10.48550/ARXIV.2305.02012. URL <https://arxiv.org/abs/2305.02012>.
- [3] Aron Park, Yeeun Lee, and Seungyoon Nam. A performance evaluation of drug response prediction models for individual drugs. *Scientific Reports*, 13(1), July 2023. ISSN 2045-2322. doi: 10.1038/s41598-023-39179-2. URL <http://dx.doi.org/10.1038/s41598-023-39179-2>.
- [4] William J. MacDonald, Connor Purcell, Maximilian Pinho-Schwermann, Nolan M. Stubbs, Praveen R. Srinivasan, and Wafik S. El-Deiry. Heterogeneity in cancer. *Cancers*, 17(3):441, January 2025. ISSN 2072-6694. doi: 10.3390/cancers17030441. URL <http://dx.doi.org/10.3390/cancers17030441>.
- [5] Michael Schlander, Karla Hernandez-Villafuerte, Chih-Yuan Cheng, Jorge Mestre-Ferrandiz, and Michael Baumann. How much does it cost to research and develop a new drug? a systematic review and assessment. *PharmacoEconomics*, 39(11): 1243–1269, August 2021. ISSN 1179-2027. doi: 10.1007/s40273-021-01065-y. URL <http://dx.doi.org/10.1007/s40273-021-01065-y>.
- [6] Senem Aykul and Erik Martinez-Hackert. Determination of half-maximal inhibitory concentration using biosensor-based protein interaction analysis. *Analytical Biochemistry*, 508:97–103, September 2016. doi: 10.1016/j.ab.2016.06.025. URL <https://doi.org/10.1016/j.ab.2016.06.025>.
- [7] Jordi Barretina, Giordano Caponigro, Nicolas Stransky, Kavitha Venkatesan, Adam A. Margolin, Sungjoon Kim, Christopher J. Wilson, Joseph Lehár, Gregory V. Kryukov, Dmitriy Sonkin, Anupama Reddy, Manway Liu, Lauren Murray, Michael F. Berger, John E. Monahan, Paula Morais, Jodi Meltzer, Adam Korejwa, Judit Jané-Valbuena, Filipa A. Mapa, Joseph Thibault, Eva Bric-Furlong, Pichai Raman, Aaron Shipway, Ingo H. Engels, Jill Cheng, Guoying K. Yu, Jianjun Yu, Peter Aspesi, Melanie de Silva, Kalpana Jagtap, Michael D. Jones, Li Wang, Charles Hatton, Emanuele Palessandolo, Supriya Gupta, Scott Mahan, Carrie Sougnez, Robert C. Onofrio, Ted Liefeld, Laura MacConaill, Wendy Winckler, Michael Reich, Nanxin Li, Jill P. Mesirov, Stacey B. Gabriel, Gad Getz, Kristin Ardlie, Vivien Chan, Vic E. Myer, Barbara L. Weber, Jeff Porter, Markus Warmuth, Peter Finan, Jennifer L. Harris, Matthew Meyerson, Todd R. Golub,

- Michael P. Morrissey, William R. Sellers, Robert Schlegel, and Levi A. Garraway. The cancer cell line encyclopedia enables predictive modelling of anticancer drug sensitivity. *Nature*, 483(7391):603–607, March 2012. ISSN 1476-4687. doi: 10.1038/nature11003. URL <http://dx.doi.org/10.1038/nature11003>.
- [8] Francesco Iorio, Theo A. Knijnenburg, Daniel J. Vis, Graham R. Bignell, Michael P. Menden, Michael Schubert, Nanne Aben, Emanuel Gonçalves, Syd Barthorpe, Howard Lightfoot, Thomas Cokelaer, Patricia Greninger, Ewald van Dyk, Han Chang, Heshani de Silva, Holger Heyn, Xianming Deng, Regina K. Egan, Qingsong Liu, Tatiana Mironenko, Xeni Mitropoulos, Laura Richardson, Jinhua Wang, Tinghu Zhang, Sebastian Moran, Sergi Sayols, Maryam Soleimani, David Tamborero, Nuria Lopez-Bigas, Petra Ross-Macdonald, Manel Esteller, Nathanael S. Gray, Daniel A. Haber, Michael R. Stratton, Cyril H. Benes, Lodewyk F.A. Wessels, Julio Saez-Rodriguez, Ultan McDermott, and Mathew J. Garnett. A landscape of pharmacogenomic interactions in cancer. *Cell*, 166(3):740–754, July 2016. ISSN 0092-8674. doi: 10.1016/j.cell.2016.06.017. URL <http://dx.doi.org/10.1016/j.cell.2016.06.017>.
- [9] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer. Smote: Synthetic minority over-sampling technique. 2011. doi: 10.48550/ARXIV.1106.1813. URL <https://arxiv.org/abs/1106.1813>.
- [10] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework, 2019. URL <https://arxiv.org/abs/1907.10902>.
- [11] Claire N. Harrison, Nicolaas Schaap, Alessandro M. Vannucchi, Jean-Jacques Kiladjian, Francesco Passamonti, Sonja Zweegman, Moshe Talpaz, Srđan Verstovsek, Shelonitda Rose, Jun Zhang, Oumar Sy, and Ruben A. Mesa. Safety and efficacy of fedratinib, a selective oral inhibitor of janus kinase-2 (<scp>jak2</scp>), in patients with myelofibrosis and low pretreatment platelet counts. *British Journal of Haematology*, 198(2):317–327, April 2022. ISSN 1365-2141. doi: 10.1111/bjh.18207. URL <http://dx.doi.org/10.1111/bjh.18207>.
- [12] Shigeru Iwata, Yohei Mikami, Hong-Wei Sun, Stephen R. Brooks, Dragana Jankovic, Kiyoshi Hirahara, Atsushi Onodera, Han-Yu Shih, Takeshi Kawabe, Kan Jiang, Toshinori Nakayama, Alan Sher, John J. O’Shea, Fred P. Davis, and Yuka Kanno. The transcription factor t-bet limits amplification of type i ifn transcriptome and circuitry in t helper 1 cells. *Immunity*, 46(6):983–991.e4, June 2017. ISSN 1074-7613. doi: 10.1016/j.immuni.2017.05.005. URL <http://dx.doi.org/10.1016/j.immuni.2017.05.005>.
- [13] Xingying Zhang, Xin Wen, Ning Feng, Aoxing Chen, Senbang Yao, Xin Ding, and Longzhen Zhang. Increased expression of t-box transcription factor protein 21 (tbx21) in skin cutaneous melanoma predicts better prognosis: A study based on the cancer genome atlas (tcga) and genotype-tissue expression (gtex) databases. *Medical Science Monitor*, 26, June 2020. ISSN 1643-3750. doi: 10.12659/msm.923087. URL <http://dx.doi.org/10.12659/MSM.923087>.
- [14] Shinya Ogawa, Masanobu Satake, and Koichi Ikuta. Physical and functional interactions between stat5 and runx transcription factors. *The Journal of Biochemistry*, 143(5): 695–709, February 2008. ISSN 0021-924X. doi: 10.1093/jb/mvn022. URL <http://dx.doi.org/10.1093/jb/mvn022>.

- [15] Tamotsu Irino, Munehiro Uemura, Humitsugu Yamane, Shigeto Umemura, Takahiko Utsumi, Naoki Kakazu, Taku Shirakawa, Mitsuhiro Ito, Takayo Suzuki, and Kazuo Kinoshita. Jak2 v617f-dependent upregulation of pu.1 expression in the peripheral blood of myeloproliferative neoplasm patients. *PLoS ONE*, 6(7):e22148, July 2011. ISSN 1932-6203. doi: 10.1371/journal.pone.0022148. URL <http://dx.doi.org/10.1371/journal.pone.0022148>.
- [16] Zaigham M. Khan, Alexander M. Real, William M. Marsiglia, Arthur Chow, Mary E. Duffy, Jayasudhan R. Yerabolu, Alex P. Scpton, and Arvin C. Dar. Structural basis for the action of the drug trametinib at ksr-bound mek. *Nature*, 588(7838):509–514, September 2020. ISSN 1476-4687. doi: 10.1038/s41586-020-2760-4. URL <http://dx.doi.org/10.1038/s41586-020-2760-4>.
- [17] Ding-Guo Wang, Jian Gao, Jing Wang, Kun-Chao Li, Zhi-Bo Wu, Zhong-Min Liao, and Yong-Bing Wu. Tfp2a drives non-small cell lung cancer (nslc) progression and resistance to targeted therapy by facilitating the esr2-mediated mapk pathway. *Cell Death Discovery*, 10(1), December 2024. ISSN 2058-7716. doi: 10.1038/s41420-024-02251-5. URL <http://dx.doi.org/10.1038/s41420-024-02251-5>.
- [18] Posit team. Rstudio: Integrated development environment for r. *Posit Software, PBC*, 2025. URL <http://www.posit.co/>.
- [19] Python Software Foundation. Python programming language. *Python Software Foundation*, 3.11, 2024. URL <https://www.python.org/>. Version 3.11.